

# **ESCUELA POLITÉCNICA NACIONAL**

## **FACULTAD DE INGENIERÍA DE SISTEMAS**

**RECONOCIMIENTO DE GESTOS DE LA MANO EN TIEMPO REAL  
BASADO EN SEÑALES ELECTROMIOGRÁFICAS UTILIZANDO  
MYO ARMBAND CON WAVELETS Y MÁQUINAS DE VECTORES  
DE SOPORTE.**

**TRABAJO DE TITULACIÓN PREVIO A LA OBTENCIÓN DEL TÍTULO DE  
INGENIERO EN SISTEMAS INFORMÁTICOS Y DE COMPUTACIÓN**

**LUIS DANIEL UNAPANTA BENAVIDES**

**[luis.unapanta@epn.edu.ec](mailto:luis.unapanta@epn.edu.ec)**

**DIRECTOR: MARCO E. BENALCÁZAR, PH. D.**

**[marco.benalcazar@epn.edu.ec](mailto:marco.benalcazar@epn.edu.ec)**

**CODIRECTOR: MSC. ANDRES GABRIEL JARAMILLO YÁNEZ**

**[andres.jaramilloy@epn.edu.ec](mailto:andres.jaramilloy@epn.edu.ec)**

**Quito, abril del 2019**

## **AVAL**

Certificamos que el presente trabajo fue desarrollado por Luis Daniel Unapanta, bajo nuestra supervisión.

---

**MARCO E. BENALCÁZAR, PH. D.  
DIRECTOR DEL TRABAJO DE TITULACIÓN**

---

**MSC. ANDRES GABRIEL JARAMILLO YÁNEZ  
CODIRECTOR DEL TRABAJO DE TITULACIÓN**

## **DECLARACIÓN DE AUTORÍA**

Yo Luis Daniel Unapanta Benavides declaro bajo juramento que el trabajo aquí descrito es de mi autoría; que no ha sido previamente presentada para ningún grado o calificación profesional; y, que he consultado las referencias bibliográficas que se incluyen en este documento.

A través de la presente declaración cedo mis derechos de propiedad intelectual correspondientes a este trabajo, a la Escuela Politécnica Nacional, según lo establecido por la Ley de Propiedad Intelectual, por su Reglamento y por la normatividad institucional vigente.

---

LUIS DANIEL UNAPANTA BENAVIDES

## **DEDICATORIA**

Dedico el presente trabajo a Luis Humberto Unapanta y Consuela Benavides, mis padres, que día a día me apoyan en todas las formas y me enseñaron humildad, perseverancia, y esfuerzo, que gracias a esto pude concluir mis estudios y llegar a este momento. También dedico a todos mis compañeros y amigos que formaron parte de mis historias embadurnadas de chistes y roces en la Escuela Politécnica Nacional.

Luis Daniel Unapanta

## **AGRADECIMIENTO**

A mis padres, por su paciencia y apoyo incondicional.

A la Escuela Politécnica Nacional, y a los profesores que formaron parte de mi educación.

A Andrés Jaramillo y Marco Benalcázar por darme la oportunidad de pertenecer al proyecto de investigación PIJ-16-13. Además de su guía y conocimiento brindado para la realización de este trabajo.

A mis compañeros del proyecto de investigación PIJ-16-13 por su ayuda y grandes momentos compartidos.

A mis amigos, que indiferentes a esto no se olvidan de que son ochocientas mucho más que cien.

Luis Daniel Unapanta

## ÍNDICE DE CONTENIDO

AVAL.....	I
DECLARACIÓN DE AUTORÍA .....	II
DEDICATORIA .....	III
AGRADECIMIENTO .....	IV
ÍNDICE DE CONTENIDO.....	V
RESUMEN.....	VII
ABSTRACT.....	VIII
1. INTRODUCCIÓN.....	1
1.1 Pregunta de investigación .....	3
1.2 Objetivo General .....	3
1.3 Objetivos Específicos.....	3
1.4 Alcance .....	3
1.5 Marco Teórico .....	4
1.5.1. Señales EMG y sus estados .....	4
1.5.2. Análisis wavelet .....	6
1.5.3. Estado del Arte .....	8
2. METODOLOGÍA.....	9
2.1. CONJUNTO DE DATOS .....	10
2.2. MATERIALES .....	10
2.2.1. Sensor Comercial Myo Armband.....	10
2.2.1. Estaciones de trabajo.....	12
2.3. MÉTODOS .....	13
2.3.1. Adquisición de datos .....	14
2.3.2. Pre-procesamiento.....	14
2.3.2.1. Segmentación .....	14
2.3.2.2. Rectificación y filtrado .....	15
2.3.3. Extracción de características .....	16
2.3.4. Clasificación.....	17
2.3.5. Post-procesamiento .....	19
3. RESULTADOS Y DISCUSIÓN .....	19
3.1. Metodología de Evaluación .....	19

3.2. Resultados .....	20
3.2.2. Resultados del reconocimiento .....	24
3.2.1. Resultados del tiempo.....	25
3.3. Discusión.....	26
4. CONCLUSIONES .....	28
5. REFERENCIAS BIBLIOGRÁFICAS.....	30
6. ANEXOS .....	35
ANEXO I .....	36

## RESUMEN

En el presente trabajo de investigación, se propone un modelo de reconocimiento de gestos de la mano. El modelo propuesto utiliza las señales electromiográficas (EMG) en estado transitorio tomadas del antebrazo. El modelo propuesto es capaz de reconocer 5 gestos de corta duración: wave in, wave out, fist, fingers spread, y double tap, y todo lo que no se reconoce dentro de los 5 gestos se determina como gesto de relajación (sin gesto). El modelo se compone de 5 etapas: adquisición de datos, pre-procesamiento, extracción de características, clasificación, y post-procesamiento. Para la adquisición de señales EMG, se usa el dispositivo comercial Myo Armband; en el pre-procesamiento se aplica rectificación y filtrado sobre la señal EMG; para la extracción de características, se usa un análisis wavelet utilizando una wavelet madre de la familia Daubechies; en la clasificación se usa máquina de vectores de soporte multi-clase con un enfoque de uno contra uno; y finalmente en el post-procesamiento se aplica un cambio de estado de un solo paso. El modelo se entrena individualmente para cada usuario y requiere 10 repeticiones de cada gesto de la mano, incluido el gesto de relajación. El modelo propuesto alcanza una exactitud de 87.5%, luego de ajustar los parámetros: familia y orden de la wavelet madre, kernel del SVM, el tamaño de la ventana de procesamiento, y el número de clasificaciones por ventana. El modelo propuesto funciona en tiempo real sobre un ambiente de altos recursos computacionales con una respuesta de tiempo promedio de 258 ms.

**PALABRAS CLAVE:** Reconocimiento de gestos de la mano, señales EMG, tiempo real, Myo Armband, aprendizaje de máquina, máquina de vectores de soporte, wavelets.

## ABSTRACT

In this research work, a hand gesture recognition model is proposed. The proposed model uses electromyography signals (EMG) in the transient state of the forearm. The proposed model is able to recognize 5 hand gestures of short duration: wave in, wave out, fist, fingers spread, and double tap, also the gesture of relaxation. The proposed model is composed of 5 stages: data acquisition, pre-processing, feature extraction, classification, and post-processing. The commercial device Myo Armband is used for the acquisition of EMG signals, rectification and filtering on the EMG signal in the pre-processing, Wavelet analysis is used with a mother wavelet of the Daubechies family for the feature extraction, multi-class support vector machine with a one-to-one approach is used in the classification, and finally, a change of state of one-step is applied in the post-processing. The model is trained individually for each user and requires 10 repetitions of each hand gesture, including the gesture of relaxation. The proposed model reaches an accuracy of 87.5 after adjusting the parameters: family and order of the mother wavelet, SVM kernel, the size of the processing window, and the number of classifications per window. The proposed model works in real time on an environment of high computational resources with an average time response of 258 ms.

**KEYWORDS:** Hand gesture recognition, EMG signals, real time, Myo Armband, machine learning, support vector machine, wavelets.

## **1. INTRODUCCIÓN**

El reconocimiento de gestos de la mano tiene como objetivo la interpretación de los movimientos de la mano identificando el gesto de la mano y el instante de tiempo cuando el gesto se realizó [1]. Los modelos de reconocimiento de gestos de la mano pueden ser utilizados en varias aplicaciones como: la interpretación de lenguajes de señas [2] [3] [4], interfaces de interacción humano-computador (HCI, por sus siglas en inglés para Human-Computer Interaction), control de prótesis activas [5] [6], control de mouse [7], interacción de objetos para videojuegos y realidad virtual [8] [9].

Un modelo de reconocimiento de gestos de la mano no debe presentar retrasos perceptibles para el usuario. Por esta razón, un factor importante para la mayoría de las aplicaciones de un modelo de reconocimiento de gestos de la mano es el procesamiento de datos en tiempo real. El tiempo de procesamiento del modelo debe ser menor a 300 ms [10]. Esto significa que aproximadamente se debe reconocer 3 gestos por cada segundo. Se debe considerar que el tiempo real es relativo, ya que el tiempo de procesamiento se encuentra limitado por los recursos computacionales donde se ejecuta el modelo. En otras palabras, un modelo de reconocimiento de gestos de la mano puede requerir más capacidad computacional para operar en tiempo real.

Otro factor importante es que los datos requeridos para el entrenamiento del modelo de reconocimiento de gestos se pueden adquirir por medio de varios dispositivos, por ejemplo, guantes, cámaras, sensores de ultrasonido, sensores electromiográficos invasivos y no invasivos. Sin embargo, cada uno de los dispositivos presenta algunas desventajas. Para el caso de los guantes el problema principal es la incompatibilidad de la talla del guante con el tamaño de la mano del usuario, y dependiendo de la aplicación y el tiempo de uso se vuelve incómodo para algunos usuarios [11]. Los problemas del uso de cámaras son: la sensibilidad a la variación de la luz y la variación de la distancia entre la mano y la cámara [12]. Los sensores de ultrasonido pueden ser afectados cuando la onda de un sensor es recibida por otro sensor o el mismo sensor recibe su propia onda si los tiempos de espera no son adecuados, a este fenómeno se lo conoce como Cross-talking. Dentro de los sensores electromiográficos tenemos los invasivos que por medio de agujas penetradas en la piel se adjuntan al músculo permitiendo una medición más confiable, útil para la electromiografía clínica exploratoria pero impráctico para las aplicaciones de un modelo de reconocimiento de gestos de la mano en los campos tecnológicos, ya que se necesita un ambiente esterilizado para no presentar riesgos de infección a la persona [13]. Los sensores electromiográficos no invasivos se ubican por encima de la piel, por lo que también se los conoce como superficiales, y nos ayudan a capturar la actividad eléctrica

de los músculos esqueléticos que es enviada por el cerebro para contraerlos y producir fuerza y/o movimiento [13]. A esta actividad se la conoce como señales electromiográficas (EMG) y son una representación específica de la intención del movimiento que realiza un usuario para generar el gesto [14]. Cabe mencionar que el uso de sensores electromiográficos superficiales posee ciertas desventajas, por ejemplo: el ruido en el ambiente, inducción electromagnética, y la interacción de señales eléctricas de otros tejidos [13]. En este trabajo se utilizan 8 sensores superficiales, que componen el dispositivo comercial Myo Armband, para la adquisición de señales EMG usadas para la realización del presente modelo de reconocimiento de gestos de la mano.

El aprendizaje de máquina es un método computacional que se puede aplicar para resolver el problema del reconocimiento de gestos de la mano. Pero al usar este método se debe tomar en cuenta problemas como por ejemplo: la extracción de las correctas características de la señal para el entrenamiento del modelo que pueden estar en el dominio del tiempo, frecuencia, o tiempo-frecuencia [15], la cantidad de clases que el modelo puede predecir [16], el reconocimiento de señales EMG en estado transitorio o estacionario [17], o la cantidad de muestras de los gestos de la mano para el entrenamiento del modelo [18].

En este trabajo de investigación se presenta un modelo de reconocimiento de gestos de la mano que responde en tiempo real y es capaz de reconocer 5 gestos de la mano y todo lo que no se reconoce dentro de los 5 gestos se determina como gesto de relajación (también llamado sin gesto). Los gestos de la mano son los mismos reconocidos por modelo de reconocimiento del Myo Armband para tener un punto de comparación. Los gestos se los muestra en la **Figura 1**. Para el reconocimiento de gestos de la mano se propone una metodología de 5 etapas: adquisición de señales EMG, pre-procesamiento, extracción de características, clasificación, y post-procesamiento. Cada etapa nos ayuda para el cumplimiento de las 3 fases del modelo: entrenamiento, validación, y testeo (Ver **Figura 2**). El modelo propuesto se entrena y adapta individualmente para cada usuario y utiliza gestos de la mano de corta duración como entrada, características en el dominio de tiempo-frecuencia por medio de un análisis Wavelet, y máquinas de vectores de soporte como clasificador.



**Figura 1.** Gestos de la mano reconocidos por el modelo propuesto.



**Figura 2.** Fases del modelo propuesto.

### 1.1 Pregunta de investigación

Utilizando Wavelets, Máquinas de Vectores de Soporte, y el dispositivo comercial Myo Armband se podrá desarrollar un sistema de reconocimiento de gestos de la mano con un tiempo de procesamiento menor a 300 ms, logrando una exactitud de reconocimiento igual o mayor del modelo de reconocimiento del Myo Armband con una base de entrenamiento de 10 repeticiones por gesto.

### 1.2 Objetivo General

Desarrollar un modelo de reconocimiento de gestos de la mano que responda en tiempo real para lograr una exactitud de reconocimiento igual o mayor al 85% mediante un análisis Wavelets y Máquinas de Vectores de Soporte.

### 1.3 Objetivos Específicos

- Desarrollar un modelo de reconocimiento de 5 gestos de la mano humana con una base de entrenamiento de 10 repeticiones por gesto, utilizando Wavelets y Máquinas de Vectores de Soporte.
- Comparar los resultados obtenidos del modelo planteado con los modelos de reconocimiento de la literatura científica y del sensor comercial Myo Armband.

### 1.4 Alcance

El presente trabajo de investigación muestra el desarrollo y los resultados de un modelo de reconocimiento de gestos de la mano. El modelo se compone por 5 etapas donde: se utilizará el sensor comercial Myo Armband para la adquisición de las señales EMG del antebrazo, se aplicará rectificación y filtrado sobre señal EMG en el pre-procesamiento, un análisis Wavelet para la extracción de características, máquinas de vectores de soporte

para la clasificación, y un cambio de estado de un paso en el post-procesamiento. El modelo se entrenará de manera individual por cada usuario y una base de entrenamiento de 10 repeticiones por cada gesto de la mano. El tiempo de respuesta será menor que 300 ms, para reconocer 5 gestos de la mano (wave in, wave out, fist, fingers spread, y double tap).

## 1.5 Marco Teórico

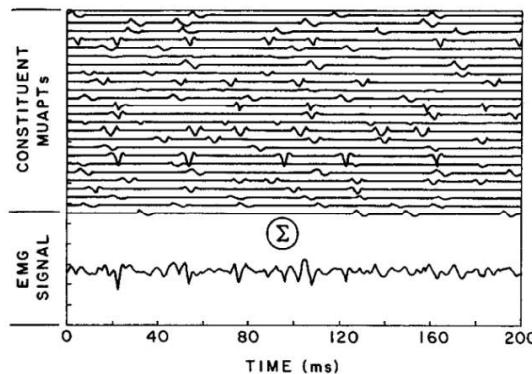
### 1.5.1. Señales EMG y sus estados

Las señales electromiográficas (EMG) son la medida del sistema neuromuscular que registra la actividad eléctrica de los músculos esqueléticos [14]. El movimiento de las extremidades está controlado por las señales eléctricas que viajan entre el sistema nervioso central y periférico hacia los músculos [19]. La contracción de los músculos esqueléticos es el resultado de la contracción de múltiples unidades motoras. Una unidad motora es un conjunto de múltiples fibras musculares inervadas en una sola neurona motora [20]. Una fibra muscular es activada por impulsos provenientes de una neurona motora. Los disparos de la unidad motora son la tasa de excitación de las unidades motoras que producen la fuerza de contracción a las fibras musculares individuales. Cada vez que se produce un disparo de la unidad motora se produce un potencial de acción de la unidad motora (MUAP por sus siglas en inglés para Motor Unit Action Potential). El MUAP es el potencial eléctrico producido por una unidad motora hacia las fibras musculares. Cuando un músculo se contrae, los potenciales de acción de la unidad motora forman un tren de potenciales de acción de la unidad motora (MUAPT por sus siglas en inglés para Motor Unit Action Potential Train) [13]. Una señal EMG es la suma algebraica de todas las MUAPT de todas las unidades motoras activas dentro del área de captura de un electrodo o sensor (Ver **Figura 3**) [13] [21]. La señal EMG proporciona información sobre el funcionamiento total de todo el sistema motor (i.e., las neuronas motoras, la unión neuromuscular, y el músculo) y, por lo tanto, es una representación específica de la intención del movimiento que ejecuta un usuario al realizar un gesto de la mano [22].

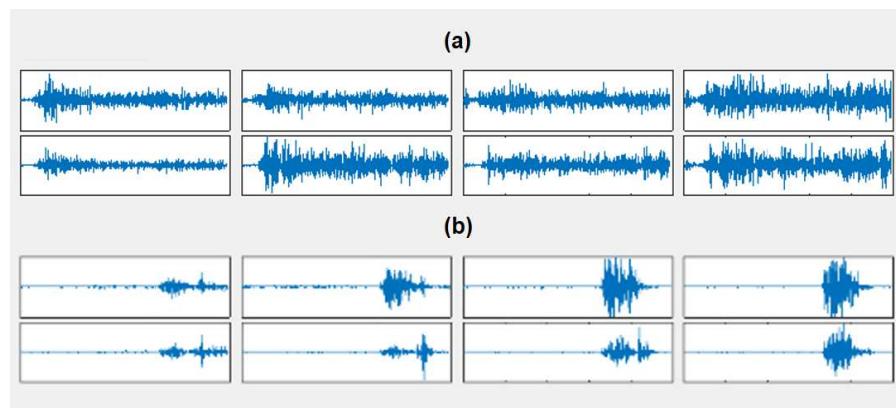
Durante la contracción muscular existen dos estados principales en las señales EMG que pueden ser reconocidos: estado estacionario y estado transitorio. El estado estacionario se produce cuando la contracción muscular es sostenida y sin modificación, es decir que corresponden a la parte de la contracción muscular cuando las unidades motoras involucradas en el movimiento del gesto de la mano ya se encuentran activadas de forma estable [23]. El estado transitorio es el producto de una contracción muscular repentina y de manera no sostenida, es decir que corresponde al inicio de la activación de las unidades

motoras involucradas al realizar el movimiento del gesto de la mano [23]. Los gestos de larga duración generan en su mayoría señales EMG en estado estacionario porque el gesto es sostenido y no se modifica en el transcurso del tiempo (**Figura 4.a**). Por otra parte, los gestos de corta duración generan señales EMG en estado transitorio porque el gesto se realiza de manera repentina y de manera interrumpida en el transcurso del tiempo (**Figura 4.b**).

Por su naturaleza menos compleja, el reconocimiento o clasificación de las señales de EMG en estado estacionario alcanza un mayor porcentaje de exactitud que en el estado transitorio [24]. En este trabajo, se optó por analizar señales EMG en estado transitorio porque para las aplicaciones prácticas sobre los campos tecnológicos y científicos mencionados en la introducción necesitan identificar el movimiento de los gestos de la mano mientras se genera la contracción muscular y no esperar a que el movimiento del gesto alcance un estado estacionario o estable.



**Figura 3.** Señal EMG formada por la suma de MUAPs [13].



**Figura 4.** Señal EMG capturada por los 8 sensores del Myo Armband de: **(a)** un gesto de larga duración y **(b)** un gesto de corta duración.

### 1.5.2. Análisis wavelet

El comportamiento de la señal EMG es un proceso no estacionario estocástico, es decir, que la varianza cambia en función del tiempo [22]. Para obtener información significativa de las señales EMG (i.e., extracción de características), se pueden aplicar diferentes técnicas a los datos en el dominio del tiempo, el dominio de la frecuencia y el dominio de tiempo-frecuencia [25]. Entre las técnicas basadas en el dominio de tiempo-frecuencia, tenemos la Transformada Wavelet que permite un análisis local de señales no estacionarias y de rápida transitoriedad [26]. La transformada Wavelet nos permite este análisis en señales como, por ejemplo: electrocardiográficas [27], electromiografías, sísmicas [28], de sonido [29], de radar [30], también se utiliza para el procesamiento de imágenes y reconocimiento de patrones [26]. El producto de este análisis es una gran cantidad de datos que representan de manera local el comportamiento de la señal. La Transformada Wavelet es la descomposición de una función  $f(t)$  en un conjunto de funciones  $\psi_{s,\tau}(t)$ , que forman una base llamada Wavelets. La Transformada Wavelet está definida por la **ecuación 1**.

$$W_f(s, \tau) = \int f(t)\psi_{s,\tau}(t)dt$$

**Ecuación 1.** Transformada Wavelet.

Las Wavelets son generadas de la translación y la escala de una misma función Wavelet  $\psi(t)$ , llamadas Wavelet Madre definida por la **ecuación 2**.

$$\Psi_{s,\tau}(t) = \frac{1}{\sqrt{s}} \psi\left(\frac{t-\tau}{s}\right); s, \tau \in \mathbb{R} \wedge s > 0$$

**Ecuación 2.** Wavelet Madre.

En la ecuación 2,  $s$  es el factor de escala, y  $\tau$  es el factor de translación. Las wavelets generadas de la misma Wavelet Madre  $\psi(t)$ , tienen diferentes escalas  $s$  y traslaciones  $\tau$ , pero tienen la misma forma. Las Wavelets son dilatadas cuando la escala  $s > 1$ , y son contraídas cuando  $0 < s < 1$ . Así, cambiando el valor de la escala se cubren rangos diferentes de frecuencias. Valores grandes del parámetro  $s$ , o una escala grande de  $\psi_{s,\tau}(t)$ , corresponden a un rango de bajas frecuencias. Valores pequeños de  $s$  o una escala muy pequeña de  $\psi_{s,\tau}(t)$ , corresponde a un rango de frecuencias alto. La transformada wavelet se implementa a través de un árbol de filtrado jerárquico, organizado en etapas llamadas niveles de descomposición. Cada etapa está dividida en un filtrado de alta frecuencia y un filtrado de baja frecuencia. A la salida de cada etapa de descomposición se le denomina coeficientes de detalle, si provienen del filtro de alta frecuencia o coeficientes de

aproximación, si provienen del filtro de baja frecuencia [31]. Dependiendo de cómo se discretiza el factor de escala, las wavelets se dividen en Transformada Wavelet Continua (CWT por sus siglas en inglés para Continuous Wavelet Transform) si los factores de escala son discretizados en potencias fraccionarias de 2 y en Transformada Wavelet Discreta (DTW por sus siglas en inglés Discrete Wavelet Transform) si los factores de escala son discretizados en potencias enteras positivas de 2.

La forma que se discretizan el factor de escala y translación dan como resultado algunas diferencias entre ambas [26]. DWT siempre termina con el mismo número de coeficientes de detalle o aproximación que los datos de la señal original, a veces la mayoría de los coeficientes pueden tener un valor cercano a cero, pero luego de la eliminación de estos valores se tiene una representación de alta calidad de la señal. Por otro lado, con CWT es una transformada altamente redundante ya que existe una superposición significativa entre las wavelets de cada escala. Además, los recursos computacionales para calcular y almacenar los coeficientes de CWT son mayores que para DWT. También es relevante que DWT proporciona una reconstrucción perfecta de la señal tras su respectivo proceso de inversión. Esto significa que se puede tomar la DWT de una señal y luego usar los coeficientes para sintetizar una reproducción exacta de la señal. Se puede implementar un proceso de inversión para CWT, pero por lo general ocurre que la reconstrucción no es perfecta y el proceso es menos estable [26]. El muestreo más fino entre escalas de CWT resulta en un análisis de la señal de mayor fidelidad. Lo que facilita el localizar transitorios en su señal, o caracterizar mejor el comportamiento oscilatorio con CWT que con DWT [26].

En el presente trabajo, se optó por el uso de un análisis wavelet por medio de DTW para la extracción de características por su bajo costo computacional, y por su alta exactitud de clasificación de señales EMG [32]. DTW usa factores de escala y translación discretos. Los factores de escala son discretizados en potencias enteras de 2 (i.e.,  $s = 2^i$  donde  $i \in \mathbb{Z}^+$ ). Por lo tanto, aplicando este concepto en la Ecuación 2, DTW toma la forma de la **Ecuación 3**.

$$\Psi_{s,\tau}(t) = \frac{1}{\sqrt{2^i}} \psi\left(\frac{t-\tau}{2^i}\right)$$

**Ecuación 3.** Transformada Wavelet Discreta.

Si la función DTW forma una base ortonormal, una función  $f(t)$  puede ser reconstruida como la suma de los coeficientes wavelets discretos  $W_f(s, \tau)$  multiplicado por las funciones de la base, la fórmula de la reconstrucción se encuentra en la **Ecuación 4**.

$$f(t) = \sum_s \sum_{\tau} W_f(s, \tau) \psi_{s, \tau}(t)$$

**Ecuación 4.** Reconstrucción de la señal.

### 1.5.3. Estado del Arte

Existen varios trabajos de investigación que abordan el problema del reconocimiento o clasificación de gestos de la mano. En esta revisión del estado del arte se limitó a modelos de reconocimiento de gestos de la mano basados en señales EMG y que utilizan técnicas de aprendizaje de máquina supervisado para resolver el problema. Dentro de estos trabajos de investigación se encontró que los clasificadores más comunes son: redes neuronales artificiales (ANN por sus siglas para Artificial Neural Network), máquinas de vectores de soporte (SVM por sus siglas en inglés para Support Vector Machine), y k vecinos más cercanos (kNN por sus siglas en inglés para k-Nearest Neighbors). También cada trabajo utiliza diferentes tipos de características que se encuentran en el dominio del tiempo, frecuencia, o ambas. Hay trabajos de investigación que proponen modelos con altos porcentajes de exactitud, por ejemplo, en [4] un sistema de reconocimiento de gestos de larga duración con una exactitud de aproximadamente de 100%, usando características en el dominio del tiempo y un perceptrón multicapa con un algoritmo de retro-propagación del error para el entrenamiento, es capaz de reconocer 4 gestos. En el trabajo [33], alcanza una exactitud de 96.7%, usando características en el dominio del tiempo y ANN, reconoce 5 gestos, pero no especifica la duración del gesto. En el trabajo [34] se obtiene un 98% de exactitud, usando características en el dominio del tiempo y en dominio de la frecuencia, ANN como clasificador y es capaz de reconocer 18 gestos de larga duración. Aunque estos modelos alcanzan altos porcentajes de exactitud el principal problema es que no funcionan en tiempo real y utilizan señales EMG en estado estacionario. Por este motivo son imprácticos para varias aplicaciones y necesidades en los campos tecnológicos y científicos mencionados en la introducción.

Por otra parte, existen trabajos de investigación que plantean modelos de reconocimiento o clasificación de gestos de la mano que funcionan en tiempo real. Dentro de los modelos que usan SVM, en el trabajo [3] alcanza una exactitud de 82.3%, con características en el dominio del tiempo. El modelo clasifica 26 gestos de la mano de larga duración. El trabajo [35] reconoce 4 gestos de larga duración y alcanza una exactitud de 87%, usando características en el dominio del tiempo. En el trabajo [16] se obtiene una exactitud de 88% y clasifica 3 gestos de la mano. Este modelo no especifica el uso de gestos de larga o corta duración. Aunque lo interesante de este trabajo es su sistema de bajo consumo energético,

el principal problema es la poca cantidad de gestos que clasifica el modelo. Dentro de los modelos que usan ANN, tenemos trabajos como, el [36] que alcanzan una exactitud de 83.5% para clasificar 4 gestos. Este modelo usa características en el dominio del tiempo y en el dominio de la frecuencia, pero no especifica la duración del gesto. En [37], usando características en el dominio del tiempo, y una red neuronal feed-forward con un algoritmo de retro-propagación del error (BP por sus siglas en inglés para backpropagation), alcanza un 71% de exactitud capaz de reconocer 6 gestos de larga duración. En [38], usando dos arquitecturas diferentes de un clasificador ANN, características en el dominio del tiempo alcanzan una exactitud de 83.43% para clasificar 9 gestos de larga duración. Finalmente, dentro de los modelos que utilizan KNN, tenemos el trabajo [39], que alcanza un 86% de exactitud, usando características en el dominio del tiempo y un algoritmo de Alineamiento Temporal Dinámico (DTW por sus siglas en inglés para Dynamic Time Warping), reconocen 5 gestos de corta duración. Se debe tomar en consideración, que para los modelos mencionados superan las 10 repeticiones de entrenamiento o no lo mencionan, y no realizan un análisis completo ya que no mencionan la sensibilidad, precisión, tiempo de procesamiento, desviaciones estándares, y su metodología de evaluación de clasificación o reconocimiento. Del mismo modo no todos los trabajos mencionan la cantidad de personas voluntarios que probaron para determinar la exactitud del modelo de reconocimiento de gestos de la mano que proponen. La mayoría de los modelos utilizan gestos de larga duración por lo que las señales EMG que clasifican o reconocen están en estado estacionario. Cabe mencionar que en cuanto a la exactitud de reconocimiento se tiene un promedio de alrededor de 85% para modelos que usan sensores electromiográficos que coincide con los sistemas de alta tecnología más avanzados [16].

El resto del trabajo se ha organizado de la siguiente manera: en el segundo capítulo, se presenta la metodología, en el cual se describe el conjunto de datos, materiales y métodos utilizados para la realización del modelo propuesto. En el tercer capítulo, se presenta la metodología de evaluación y los resultados obtenidos a partir de la evaluación. Finalmente, en el cuarto capítulo, se presenta las conclusiones y las recomendaciones para el trabajo futuro.

## **2. METODOLOGÍA**

En este capítulo, se describe el conjunto de datos, los materiales, y los métodos utilizados para el desarrollo de la metodología.

## **2.1. CONJUNTO DE DATOS**

En este trabajo, utilizamos los datos de 120 personas voluntarias. Cada voluntario realizó 50 repeticiones por cada uno de los 5 gestos de la mano y 10 repeticiones para el gesto de relajación. En total se grabaron 31200 repeticiones. Cada repetición de cada gesto se grabó durante un tiempo de 5 segundos, obtenido 1000 valores por cada uno de los 8 sensores o canales del Myo Armband. A los voluntarios se les solicitó utilizar el Myo Armband en el antebrazo derecho con el LED de estado de encendido apuntando hacia la mano. Aunque se grabaron 5 segundos, el gesto de la mano se realizó de forma breve. Para cada repetición los voluntarios comenzaban en la posición de relajación, continuaban a realizar el gesto de la mano, y terminaron con la posición de relajación hasta el final de la grabación.

Además de grabar las señales electromiográficas de cada gesto, se guardó el nombre del gesto realizado, la información básica del voluntario, y las lecturas IMU. Dentro de la información básica del voluntario, se incluye el nombre, el género (75% hombres, y 25% mujeres), la edad (entre 17 a 29 años), la mano de dominio (81% diestros, y 19% zurdos), y si alguna vez sufrieron una lesión grave en su brazo derecho (16% sufrió una lesión).

Los datos de las 120 personas se dividieron en dos partes iguales, 60 personas para entrenamiento y validación (testeo), y 60 personas para entrenamiento y la evaluación final (testeo). El primer conjunto nos ayuda con el desarrollo del modelo, y el segundo se utiliza cuando el modelo se encuentra terminado para la evaluación final. Dentro de cada conjunto de datos se dividió por persona 25 muestras de cada gesto para entrenamiento, y 25 muestras para testeo. Los datos del gesto de relajación se usaron solo para entrenamiento en cada conjunto de datos. En este trabajo, se usó 10 repeticiones de cada gesto para el entrenamiento del modelo.

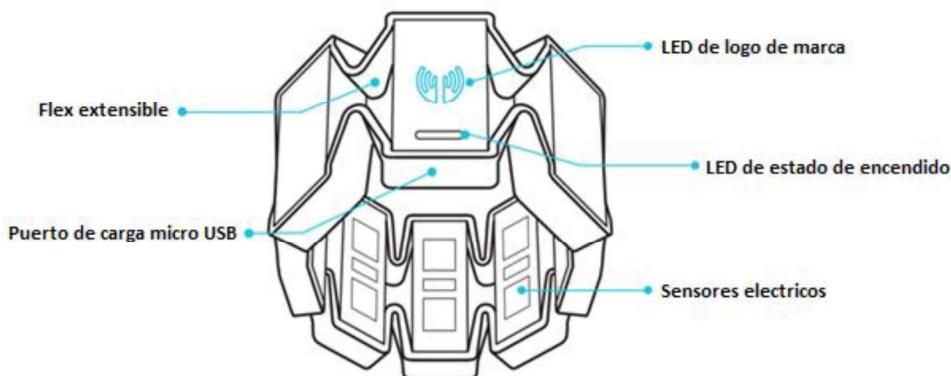
## **2.2. MATERIALES**

En esta sección, se describe las características principales del sensor comercial Myo Armband y las estaciones de trabajo utilizadas para la realización del modelo propuesto.

### **2.2.1. Sensor Comercial Myo Armband**

En este trabajo, utilizamos el sensor comercial llamado Myo Armband para la adquisición de datos, la estructura física del dispositivo se muestra en la **Figura 5**. Este es un dispositivo distribuido en el mercado desde el 2014 por la empresa canadiense Thalmic Labs Inc. Este dispositivo tiene forma de pulsera y está compuesta por 8 sensores superficiales. Cada sensor mide la actividad eléctrica de los músculos a una frecuencia de

muestreo de 200 Hz y a una resolución de 8 bits con datos entre -127 a 128. El dispositivo incluye una unidad de medición inercial (IMU) con nueve grados de libertad altamente sensibles (giroscopio de tres ejes, acelerómetro de tres ejes y magnetómetro de tres ejes). El Myo Armband utiliza Bluetooth 4.0 de baja energía para comunicarse con otros dispositivos, tiene una batería recargable de litio y cuenta con un procesador interno ARM, los elementos que incluye el paquete de compra se describen en la **Figura 6**. La empresa desarrolladora del dispositivo ofrece un campo amplio de posibilidades de desarrollo con su Software Development Kit (SDK) válido para las plataformas Windows, Mac, iOS, y Android. Se eligió este dispositivo por su bajo precio, y su fácil colocación en cualquier tamaño de antebrazo. El perímetro del dispositivo puede extenderse entre 18 a 34 cm. Además, el dispositivo cuenta con un sistema propietario con un modelo general de reconocimiento para 5 gestos de la mano, descritos en la **Tabla 1**.



**Figura 5.** Partes del Myo Armband.



**Figura 6.** Elementos del paquete Myo Armband.

**Tabla 1.** Descripción de los gestos reconocidos.

Nombre del gesto	Descripción	Gráfico
Wave in	El gesto consiste en la mano con los dedos juntos y la muñeca inclinada para formar un ángulo de 90° hacia adentro.	
Wave out	El gesto consiste en la mano con los dedos juntos y la muñeca inclinada para formar un ángulo de 90° hacia afuera.	
Fist	El gesto consiste en la mano formando un puño sin inclinación.	
Fingers spread	El gesto consiste en la mano abierta con los dedos extendidos sin inclinación.	
Double tap	El gesto consiste en un doble toque rápido del dedo pulgar con el dedo medio.	

### 2.2.1. Estaciones de trabajo

En este trabajo de investigación se utilizaron dos estaciones para las pruebas de tiempo, la primera es una computadora de escritorio que se describe en la **Tabla 2**, y la segunda es una computadora de altos recursos computacionales que se describe en la **Tabla 3**.

**Tabla 2.** Características de la primera estación de trabajo.

Característica	Descripción
Procesador	AMD FX-8360
Cantidad de Núcleos	8
Frecuencia básica del procesador	4 GHz
Frecuencia turbo máxima	4.2 GHz
Caché	8 MB
Memoria RAM	16 GB
Espacio en Disco Duro	1 TB
Tipo de Sistema	64 bits
Sistema Operativo	Windows 7 Professional Service Pack 1

**Tabla 3.** Características de la segunda estación de trabajo.

Característica	Descripción
Procesador	Intel® Xeon ® CPU E5-2690 v3
Cantidad de Núcleos	8
Cantidad de subprocessos	16
Frecuencia básica del procesador	2.90 GHz
Frecuencia turbo máxima	3.80 GHz
Caché	20 MB
Memoria RAM	68 GB
Espacio en Disco Duro	1 TB
Tipo de Sistema	64 bits
Sistema Operativo	Windows Server 2012 R2 Standard

### 2.3. MÉTODOS

En esta sección se describe el método para el desarrollo de un modelo de reconocimiento de gestos de la mano, compuesto por un proceso de 5 etapas ilustradas en la **Figura 7**. El proceso consta de: adquisición de datos, pre-procesamiento, extracción de características, clasificación, y post-procesamiento. Cada etapa nos ayuda con el entrenamiento, validación, testeo, y evaluación del modelo propuesto.



**Figura 7.** Etapas del modelo propuesto.

### 2.3.1. Adquisición de datos

En esta etapa, se adquirió con la ayuda del Myo Armband los datos de la señal EMG de los gestos de la mano y el gesto de relajación para el entrenamiento y testeo del modelo. Se graba por 5 segundos, pero el gesto se realiza de forma breve dentro de este tiempo (i.e., gesto de corta duración), obteniendo aproximadamente 1000 muestras entre el gesto y gesto de relajación. Se obtiene por persona y por repetición una matriz  $\mathbf{M}$  de tamaño  $8 \times n$ , donde 8 es el número de sensores del Myo Armband y  $n$  es el número de muestras adquiridas por cada repetición. Cada valor  $M_{i,j}$  representa la medición en el tiempo  $j$  por el sensor  $i$ , donde  $i = 1, 2, \dots, 8$  y  $j = 1, 2, \dots, n$ .

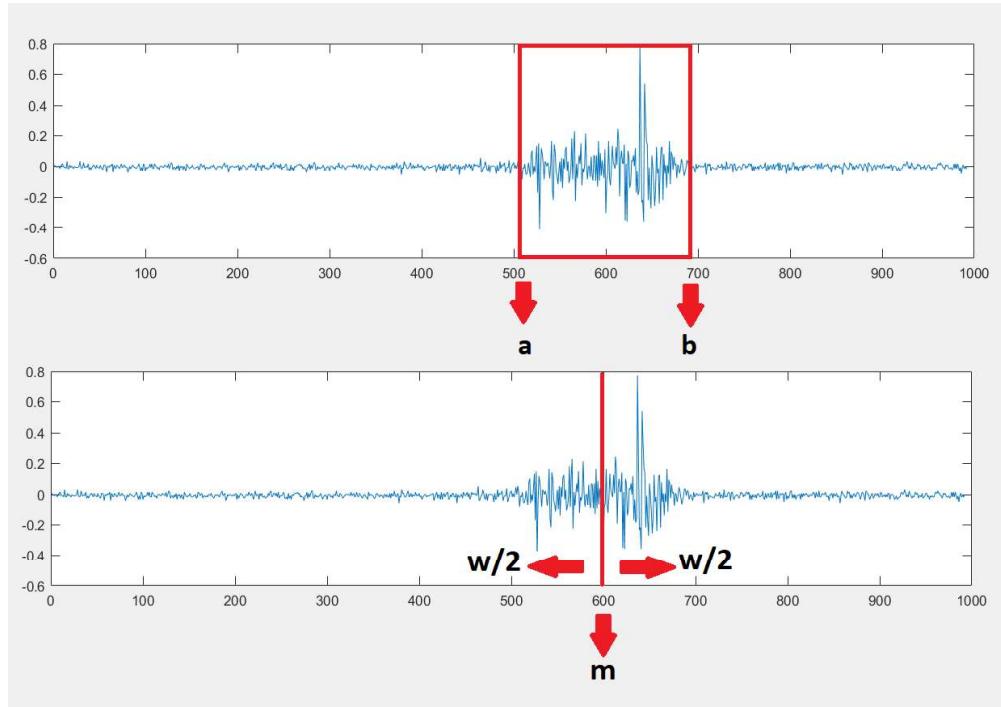
### 2.3.2. Pre-procesamiento

Las señales EMG tienen un comportamiento estocástico no estacionario porque su varianza cambia en función del tiempo [22]. Se puede reducir este comportamiento suavizando los valores de la señal EMG, de esta forma se reducen los cambios de la varianza que sufre la señal EMG en el tiempo. En esta etapa se segmentó, rectificó y filtró la señal EMG de los datos de entrenamiento, y se rectificó y filtró la señal EMG de los datos de testeo.

#### 2.3.2.1. Segmentación

Este proceso se realiza para los datos de entrenamiento, donde se aplica una función de segmentación de la actividad muscular  $\Phi$  utilizada en el trabajo de investigación [39]. Esta función devuelve los índices iniciales y finales donde se encuentra solo la actividad muscular del gesto de la mano. Esta función elimina las partes del gesto de relajación dentro de cada repetición. Los índices se aplican para cada señal EMG de cada canal ( $a_i, b_i$ ) =  $\Phi(M_i)$ , donde  $a$  es el índice inicial,  $b$  es el índice final, y  $i = 1, 2, \dots, 8$ . Luego se calcula un valor central entre los índices  $m_i = a_i - b_i$ , y se usa un valor de ventana de procesamiento  $w = 150$ . Se obtiene el valor central de la actividad muscular para evitar tomar valores del gesto de relajación. Se obtiene una matriz  $M$ , donde cada vector fila

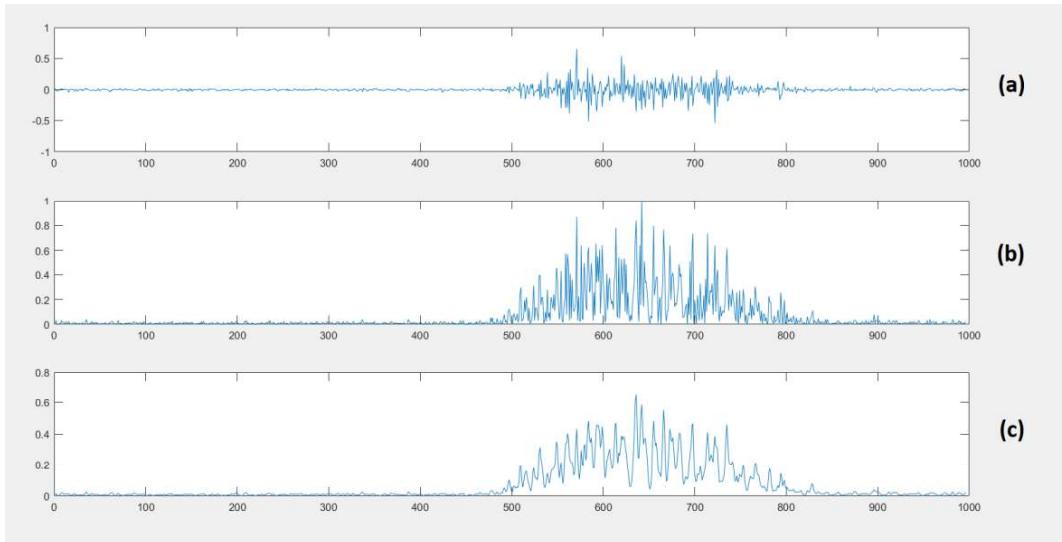
contiene una ventana con la actividad muscular del gesto, cada valor  $M_{ij}$  se define mediante un valor  $j$  entre  $[m_i - w/2, m_i + w/2]$  (ver **Figura 8**). Para las repeticiones del gesto de relajación se define el valor  $m$  igual a 500.



**Figura 8.** Proceso de segmentación de gesto y asignación de la ventana de entrenamiento.

### 2.3.2.2. Rectificación y filtrado

Este proceso se realiza para los datos de entrenamiento (luego del proceso de segmentación), validación y testeo (evaluación final). Se rectifica la matriz  $\mathbf{M}$ , obteniendo así una nueva matriz  $\mathbf{R} = \text{abs}(\mathbf{M})$ , donde se aplica valor absoluto a cada elemento de  $\mathbf{M}$ . Luego, se filtra la señal EMG de cada sensor aplicando un filtro pasa-bajos Butterworth de primer orden con una frecuencia de corte de 50 Hz, se obtiene una nueva matriz  $\mathbf{F}$ , donde cada fila vector es igual a  $\mathbf{F}_i = \Psi(\mathbf{R}_{i,1}, \dots, \mathbf{R}_{i,n})$ , donde  $i = 1, 2, \dots, 8$  y  $n$  es aproximadamente 1000. El resultado del preprocesamiento sobre la señal EMG se lo puede observar de la **Figura 9**.



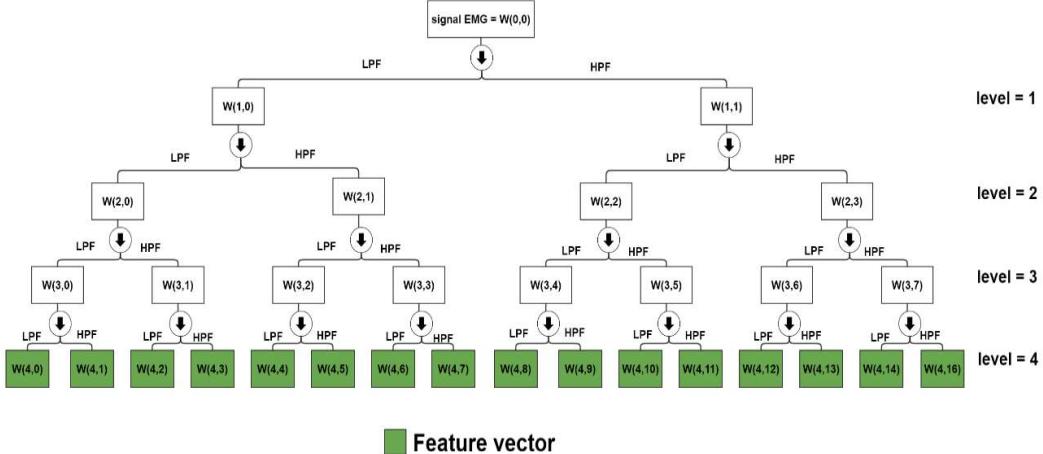
**Figura 9.** (a) Señal EMG del gesto fist adquirida del sensor comercial Myo Armband. (b) Señal EMG rectificada. (c) Señal EMG filtrada.

### 2.3.3. Extracción de características

En esta etapa, las características en el dominio del tiempo-frecuencia de la señal EMG pre-procesada se extraen mediante un análisis wavelet utilizando DWT sobre los datos de entrenamiento y testeо. Se genera una matriz  $\mathbf{W}$  producto de la aplicación de la función DWT en cada vector fila de  $\mathbf{F}$ , donde  $\mathbf{W} = \text{dwt}(\mathbf{F}_i)$ .  $\mathbf{W}$  es una matriz de tamaño  $w \times 2^v$ , donde  $v$  es el nivel de descomposición definido para el análisis DWT, y  $w$  el tamaño de la ventana de procesamiento. El nivel de descomposición está limitado por la condición  $v \leq \text{floor}(\log_2 w)$ . En este trabajo, se define 4 como el nivel de descomposición (ver **Figura 10**). Seleccionamos un nivel de 4 porque de esa manera, obtuvimos una cantidad aceptable de datos para el entrenamiento del modelo. Se probó DTW con análisis de paquetes (i.e., la descomposición completa del árbol wavelet, ver **Figura 8**) con diferentes familias de wavelet madre: Daubechies, Coiflets, y Fejer-Korovkin.

Se establece un valor  $c$  que define el número de vectores columnas sucesivos de la matriz  $\mathbf{W}$  de cada sensor del Myo Armband que se concatenan para formar un único vector de características  $\mathbf{X}_k = \{\mathbf{W}(\text{sensor } 1)_{j+(k-1),i}^T, \dots, \mathbf{W}(\text{sensor } 8)_{j+(k-1),i}^T\}$ , donde  $i = 1, \dots, 2^v; j = 1, \dots, c; k = 1, \dots, w$ . Es decir que para cada vector de características  $\mathbf{X}$  se concatenan la transpuesta del vector columna de las 16 wavelets del nivel 4 de descomposición por un  $c$  igual a 3 que corresponden al número de instantes seguidos de características, y por los 8 canales del Myo Armband. En este trabajo, se seleccionó un valor  $c$  igual a 3 para obtener una parte significativa de los datos del gesto de la mano, y

cada vector tiene 384 características. Este proceso se realiza para cada muestra de cada gesto y cada vector representa un conjunto de características para el entrenamiento del modelo.



**Figura 10.** Esquema de descomposición Wavelet.

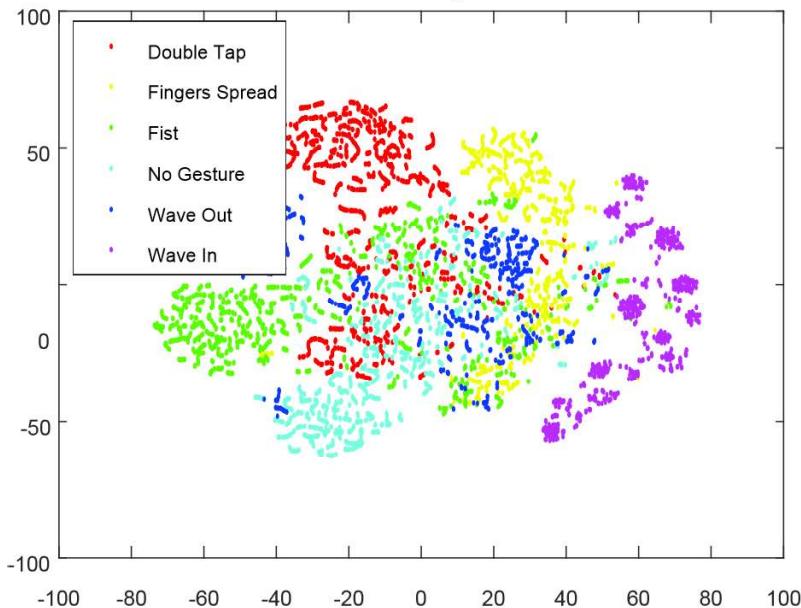
### 2.3.4. Clasificación

Para este trabajo de investigación se usa SVM, porque aprovecha al máximo la precisión de los pronósticos de un modelo sin ajustar excesivamente los datos de entrenamiento. En esta etapa, utilizamos Máquina de Vectores de Soporte multi-clase uno contra uno (OVO por sus siglas en inglés para one-vs-one) como clasificador. Máquina de Vectores de Soporte es un método de aprendizaje supervisado para resolver problemas de clasificación y regresión. SVM representa un conjunto de muestras como puntos en el espacio, donde están separados por un conjunto infinito de posibles hiperplanos. A partir de los datos de entrenamiento etiquetados, el algoritmo genera un hiperplano óptimo llamado vector de soporte que clasifica los nuevos datos. La idea es seleccionar un hiperplano separador que sea equidistante entre las muestras más cercanas de cada clase, para encontrar un margen máximo en cada lado del hiperplano. SVM es un clasificador binario no probabilístico, y para clasificar múltiples clases utiliza un enfoque uno contra todos o uno contra uno [40]. Un enfoque uno contra uno realiza  $n \times (n - 1)/2$  comparaciones donde  $n$  es el número de clases del problema (i.e., 6 clases en el caso de este trabajo), por lo que tiene un costo computacional mayor que uno contra todos que solo realiza  $n$  comparaciones. Un enfoque de uno contra uno produce una mayor exactitud de clasificación que un enfoque de uno contra todos [41]. La forma más sencilla de separar las clases es mediante una línea recta, un plano recto o un hiperplano N-dimensional. Pero existen casos, como el reconocimiento de gestos, donde el conjunto de muestras no se

puede separar completamente como se muestra en la **Figura 11**. Para este problema, las funciones matemáticas llamadas funciones kernel se utilizan para transformar las muestras en un espacio dimensional más grande [2]. La idea entonces es construir un hiperplano de separación lineal en este nuevo espacio. Se probó dos diferentes tipos de kernel: gaussiano o RBF, y polinomial. Los resultados del modelo final, que se muestran en la parte de resultados y discusión, usan un kernel gaussiano que se define en la **Ecuación 5**.

$$K(x_j, x_k) = \exp\left(-\|x_k - x_j\|^2\right)$$

**Ecuación 5.** Kernel gaussiano.

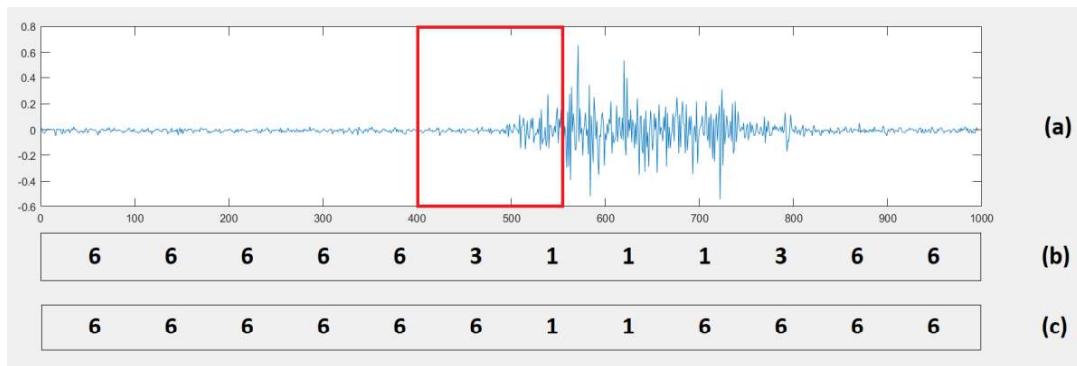


**Figura 11.** Distribución de los gestos sobre un plano bidimensional.

Para los datos de entrenamiento, se etiqueta cada vector de características  $\mathbf{X}$  con la clase  $\mathbf{Y}$  correspondiente. Luego se obtiene un modelo de clasificación del conjunto de entrenamiento etiquetado  $T = \{(Y_{(1)}, X_{(1)}); \dots; (Y_{(n)}, X_{(n)})\}$ , compuesto por  $n$  pares  $(Y_{(i)}, X_{(i)})$ , donde  $Y_{(i)}$  es la etiqueta de la clase que pertenece al vector de características  $X_{(i)}$  del gesto de la mano observado. Para el conjunto de datos de testeо, se realiza una simulación en tiempo real donde se clasifica en ventanas de 150 puntos, con una superposición de los 50 puntos. En cada ventana se clasifica equidistantemente 9 veces para tener una representación completa dentro de cada ventana. Después de obtener las 9 etiquetas, se determina un solo valor seleccionando el primer valor más frecuente. El producto de esta etapa para cada muestra de cada gesto es un vector de respuesta que representa la clase del gesto de la mano y el momento cuando ocurrió.

### 2.3.5. Post-procesamiento

En general, lo que se espera dentro de un vector de respuestas es tener al comienzo etiquetas del gesto de relajación, seguido de etiquetas del gesto realizado, y termina con etiquetas del gesto de relajación. Pero existen ventanas que no describen correctamente un solo gesto, pues contienen información del gesto de relajación y el gesto estático realizado, como se muestra en la **Figura 12 (a)**. En esta etapa, eliminamos estos defectos usando un cambio de estado de un solo paso. Para esta tarea, se asume que tenemos un vector de respuesta de tamaño  $m$  y dos etiquetas consecutivas  $y_{n-1}$  y  $y_n$  donde  $n = 2, \dots, m$ . Si  $y_{n-1}$  es igual a  $y_n$ , devolvemos el valor de  $y_n$ , de lo contrario, se devuelve el valor de la etiqueta del gesto de relajación. Completamos este proceso con cada etiqueta del vector de respuestas. En la **Figura 12 (b)** se observa el gesto antes del post-procesamiento y en la **Figura 12 (c)** luego del post-procesamiento.



**Figura 12.** Gesto de etiqueta 1 (el gesto de relajación es denotado con la etiqueta 6). (a) Ventana con defecto. (b) Vector de respuestas luego de la clasificación. (c) Vector de respuestas luego del post-procesamiento

## 3. RESULTADOS Y DISCUSIÓN

### 3.1. Metodología de Evaluación

El modelo propuesto reconoce los gestos de la mano, esto significa que determina el gesto de la mano y el momento en que ocurrió. Por este motivo, se realiza una evaluación basada en estos dos factores. Se determina una sola etiqueta del vector de respuesta con el fin de evaluar el modelo, se obtuvó 5 posibles casos de evaluación que se describen en la **Tabla 4**. Además de los casos de evaluación, se requiere identificar el momento en que se realizó el gesto de la mano. Después de obtener un vector de respuesta válido, se calcula un factor

de superposición entre los datos reales del gesto de la mano y los datos del vector de respuestas. El factor de superposición se calcula con la **Ecuación 6**.

$$\text{Factor de Superposición} = 2 * \frac{A \cap B}{A + B}$$

**Ecuación 6.** Factor de superposición.

En la Ecuación 6, **A** es la sección de la señal con actividad muscular y **B** es la sección del vector de respuesta donde se reconoció el gesto. Se utilizó un umbral de reconocimiento de 0,5. El gesto equivalente de la predicción se devuelve cuando el factor de superposición es mayor o igual al umbral de reconocimiento; de lo contrario se devuelve la etiqueta del gesto de relajación. Esta evaluación se realiza para los datos de validación y los datos de la evaluación final. En el caso de los datos de la evaluación final, el proceso de evaluación se probó solo una vez, los datos no estuvieron disponibles hasta que la versión final del modelo se desarrolló, ajustó y validó.

### 3.2. Resultados

La exactitud de reconocimiento del modelo es igual a la relación entre la suma de los verdaderos positivos (VP) y verdaderos negativos (VN) sobre la suma del número de casos positivos (P) y los negativos (N), mostrada en la **Ecuación 6**. La sensibilidad es la razón entre los verdaderos positivos y la suma de los verdaderos positivos y los falsos negativos (FN), mostrada en la **Ecuación 7**. La precisión es la razón entre los verdaderos positivos sobre la suma de los verdaderos positivos y los falsos positivos (FP), se muestra en la **Ecuación 8**.

$$\text{Exactitud} = \frac{VP + VN}{P + N}$$

**Ecuación 6.** Fórmula de la exactitud en la matriz de confusión.

$$\text{Sensibilidad} = \frac{VP}{VP + FN}$$

**Ecuación 7.** Fórmula de la sensibilidad en la matriz de confusión.

$$\text{Precisión} = \frac{VP}{VP + FP}$$

**Ecuación 8.** Fórmula de la precisión en la matriz de confusión.

**Tabla 4.** Casos de evaluación sobre un gesto de etiqueta 5.

Caso	Vector de Respuestas	Predicción	Aclaración
1	[5 5 5 ... 5 5 5]	5	El gesto equivalente es el único gesto encontrado dentro del vector de respuestas.
	[3 3 3 ... 3 3 3]	3	
2	[5 ... 5 5 6 6 ... 6]	5	El gesto equivalente es el gesto encontrado diferente del gesto de relajación.
	[6 ... 6 6 5 5 ... 5]	5	
3	[1 1 1 ... 1 1 5 5 5]	1	El gesto equivalente es el que más veces apareció sin considerar al gesto de la clase correcta ni el de relajación.
	[1 1 1 5 5 5 ... 5 5]	1	
	[6...6 1 5 5 ... 5 5 6 6 6]	1	
	[6 ...6 1 1 1 ... 1 5 6 6 6]	1	
	[6 ... 6 1 1 3 3 3 5 6 ... 6]	3	
	[6 ... 6 1 3 3 6 3 5 6 ... 6]	3	
4	[6 ... 6 6 5 5 5 6 6 ... 6]	5	El gesto equivalente es el único gesto encontrado entre los gestos de relajación.
5	[5 ... 5 6 6 6 6 5 5 ... 5]	6	En el caso de que los únicos gestos diferentes del reposo correspondan a la clase correcta, pero presenten discontinuidades, el gesto equivalente es el gesto de relajación.
	[6 5 6 6 5 ... 5 5 6 ... 6]	6	
	[6 5 5 5 6 5 5 5 6 6 5 6]	6	

### 3.2.1. Pruebas de ajuste del modelo

Se realizaron varias pruebas con diferentes parámetros en la extracción de características de características y la clasificación para alcanzar el modelo propuesto. Estas pruebas solo se realizaron sobre el conjunto de datos de validación. En las primeras pruebas, se probó con diferentes tipos de kernel para el clasificador SVM: gaussiano, polinomial de grado 2 y polinomial de grado 3. También se probó con diferentes tipos de familia de wavelet madre: Daubechies, Coiflets y Fejer-Korovkin. La **Tabla 5** muestra los resultados obtenidos con una ventana de tamaño 100 y la **Tabla 6** muestra los resultados obtenidos con una ventana de tamaño 150. En base de estos resultados, en las siguientes pruebas utilizamos un kernel

gaussiano para el clasificador, una familia de wavelet madre de Daubechies para la extracción de características, y un tamaño de ventana igual a 150.

**Tabla 5.** Resultados con una ventana de tamaño de 100.

Kernel SVM	Grado del kernel polinomial	Familia de la wavelet madre	Exactitud promedio	Tiempo de procesamiento por ventana [s]
Gaussian	-	Fejer-Korovkin	85,39%	~ 0,5
Polynomial	2	Fejer-Korovkin	70,39%	~ 0,6
Polynomial	3	Fejer-Korovkin	67,64%	~ 0,6
Gaussian	-	Coiflets	85,44%	~ 0,5
Polynomial	2	Coiflets	70,75%	~ 0,6
Polynomial	3	Coiflets	67,41%	~ 0,6
Gaussian	-	Daubechies	86,76%	~ 0,4
Polynomial	2	Daubechies	73,80%	~ 0,5
Polynomial	3	Daubechies	71,20%	~ 0,5

**Tabla 6.** Resultados con una ventana de tamaño de 150.

Kernel SVM	Grado del kernel polinomial	Familia de la wavelet madre	Exactitud promedio	Tiempo de procesamiento por ventana [s]
Gaussian	-	Fejer-Korovkin	86,93%	~ 0,5
Polynomial	2	Fejer-Korovkin	76,08%	~ 0,6
Polynomial	3	Fejer-Korovkin	72,31%	~ 0,6
Gaussian	-	Coiflets	87,03%	~ 0,5
Polynomial	2	Coiflets	76,43%	~ 0,6
Polynomial	3	Coiflets	73,53%	~ 0,6
Gaussian	-	Daubechies	87,63%	~ 0,4
Polynomial	2	Daubechies	80,51%	~ 0,5
Polynomial	3	Daubechies	77,57%	~ 0,5

Luego, se probó con diferentes valores para orden de la wavelet madre de la familia Daubechies. La **Tabla 7** muestra los resultados y se observa que cuando se usa un orden más complejo, la exactitud de clasificación aumenta, pero también el tiempo de procesamiento de una ventana. Basados en estos resultados, en las siguientes pruebas

utilizamos la familia Daubechies de orden 1 al 25, porque se obtuvo una exactitud promedio aceptable. Además, se probó un valor de 7, 8 y 9 clasificaciones por ventana para obtener mejores resultados. La **Tabla 8** muestra los resultados obtenidos en la última prueba. La mejor exactitud promedio se obtuvo con un kernel gaussiano para el clasificador SVM, un DTW con una madre wavelet de la familia Daubechies de orden 25 (DB25) y 9 clasificaciones por ventana. Todas las pruebas de ajuste y validación del modelo se realizaron en una computadora de escritorio. El tiempo real se logra al ejecutar el modelo final sobre una computadora con altos recursos computacionales.

**Tabla 7.** Resultados con diferentes órdenes de wavelet madre.

Familia de la wavelet madre	Orden de la wavelet madre	Exactitud promedio	Tiempo de procesamiento por ventana [s]
Daubechies	1	85,86%	~ 0,4
Daubechies	5	86,67%	~ 0,4
Daubechies	15	87,01%	~ 0,45
Daubechies	25	87,85%	~ 0,5
Daubechies	35	87,75%	~ 0,6
Daubechies	45	88,15%	~ 0,65

**Tabla 8.** Resultados con diferentes clasificaciones por ventana.

Clasificaciones por ventana	Wavelet madre	Exactitud promedio	Tiempo de procesamiento por ventana [s]
7	DB1	86,13%	0,331
7	DB25	86,80%	0,361
8	DB1	86,72%	0,339
8	DB25	87,52%	0,374
9	DB1	86,99%	0,353
9	DB25	88,03%	0,382

### 3.2.2. Resultados del reconocimiento

Para los 60 usuarios de validación, se obtuvo una exactitud de reconocimiento promedio de 88.03% (con una desviación estándar entre los gestos de la mano de 4,13% y una desviación estándar entre los usuarios de 8,83%). La matriz de confusión se encuentra en la **Tabla 9**, donde se resalta la exactitud total en color verde y la representación de cada gesto sobre la exactitud total en color amarillo, además la exactitud de reconocimiento de cada usuario se encuentra en el **ANEXO I**. La exactitud se calcula sobre un valor total de 7500 repeticiones para validación (60 personas x 5 gestos con la mano x 25 repeticiones). La sensibilidad más alta ocurre con el gesto wave out con 94.6% y la más baja con 81.33% ocurre con el gesto fingers spread. La precisión más alta fist y la más baja con 89.64% para el gesto fingers spread.

Para los 60 usuarios de la evaluación final, se obtuvo una precisión de reconocimiento promedio de 87.53%, (con una desviación estándar entre los gestos de la mano de 5.50% y una desviación estándar entre los usuarios de 12.59%). La matriz de confusión se observa en la **Tabla 10**, donde se resalta la exactitud total en color verde y la representación de cada gesto sobre la exactitud total en color amarillo, además la exactitud de reconocimiento de cada usuario se encuentra en el **ANEXO I**. La precisión se calcula sobre un valor total de 7500 repeticiones para la evaluación final (60 personas x 5 gestos con las manos x 25 repeticiones). La sensibilidad más alta ocurre con el gesto wave out con 90.8% y la más baja con 80.60% con el gesto fingers spread. La precisión más alta con 98.55% ocurre con el gesto fist y la precisión más baja con 89.90% para el gesto wave out.

**Tabla 9.** Matriz de confusión para el conjunto de datos de validación.

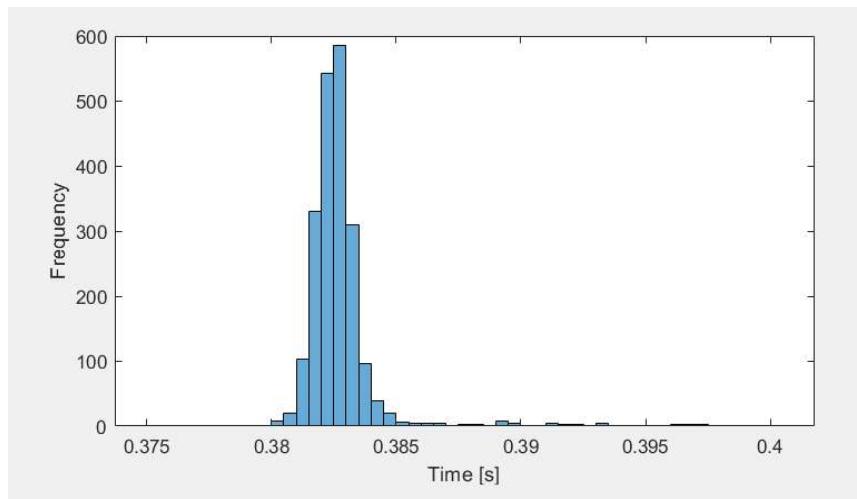
PREDICCIONES	OBSERVACIONES					%PRECISIÓN %ERROR
		WAVE IN	WAVE OUT	FIST	FINGERS SPREAD	
WAVE IN	1336 17,81%	20 0,27%	14 0,19%	14 0,19%	18 0,24%	95,29% 4,71%
WAVE OUT	20 0,27%	1419 18,92%	15 0,20%	97 1,29%	21 0,28%	90,27% 9,73%
FIST	9 0,12%	4 0,05%	1373 18,31%	13 0,17%	14 0,19%	97,17% 2,83%
FINGERS SPREAD	33 0,44%	42 0,56%	38 0,51%	1220 16,27%	28 0,37%	89,64% 10,36%
DOUBLE TAP	23 0,31%	5 0,07%	15 0,20%	13 0,17%	1254 16,72%	95,73% 4,27%
SIN GESTO	79 1,05%	10 0,13%	45 0,60%	143 1,91%	165 2,20%	0,00% 100,00%
%SENSIBILIDAD %ERROR	89,07 10,93%	94,60% 5,40%	91,53% 8,47%	81,33% 18,67%	83,60% 16,40%	88,03% 11,97%

**Tabla 10.** Matriz de confusión para los datos de evaluación.

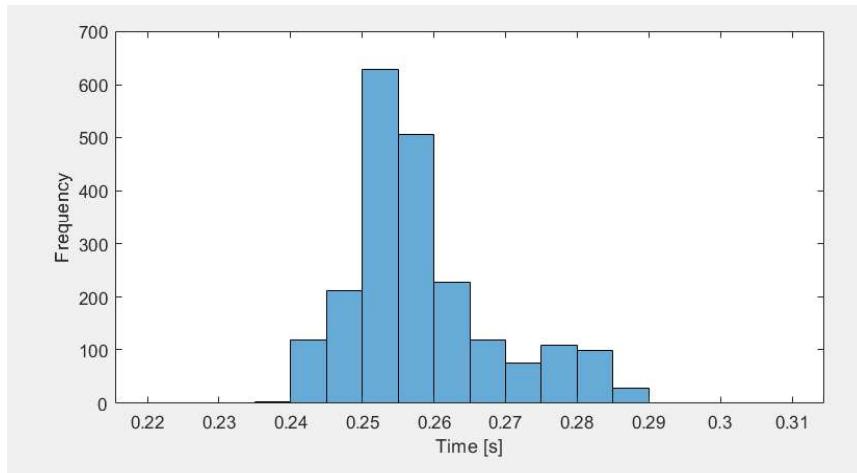
PREDICCIONES	OBSERVACIONES					%PRECISIÓN %ERROR
		WAVE IN	WAVE OUT	FIST	FINGERS SPREAD	
WAVE IN	1310 17,47%	69 0,92%	27 0,36%	15 0,20%	9 0,12%	91,61% 8,39%
WAVE OUT	31 0,41%	1362 18,16%	17 0,23%	76 1,01%	29 0,39%	89,90% 10,10%
FIST	4 0,05%	5 0,07%	1357 18,09%	5 0,07%	6 0,08%	98,55% 1,45%
FINGERS SPREAD	17 0,23%	34 0,45%	36 0,48%	1209 16,12%	25 0,33%	91,52% 8,48%
DOUBLE TAP	41 0,55%	8 0,11%	18 0,24%	17 0,23%	1327 17,69%	94,05% 5,95%
SIN GESTO	97 1,29%	22 0,29%	45 0,60%	178 2,37%	104 1,39%	0,00% 100,00%
%SENSIBILIDAD %ERROR	87,33 12,67%	90,80% 9,20%	90,47% 9,53%	80,60% 19,40%	88,47% 11,53%	87,53% 12,47%

### 3.2.1. Resultados del tiempo

En las pruebas del tiempo real del modelo propuesto se simula un desplazamiento de ventanas y se mide el tiempo de procesamiento de cada ventana. Las pruebas se ejecutaron sobre dos ambientes diferentes de hardware. El primero fue en una computadora de escritorio con un procesador AMD FX-8360 a 4 GHz, y 16 GB de RAM. Sobre este ambiente, los tiempos de procesamiento superaron los 300 milisegundos con un promedio de 382 ms. La **Figura 15** muestra el histograma del tiempo de procesamiento para un usuario en el primer entorno. El segundo ambiente fue en una computadora de altos recursos computacionales un procesador Intel ® Xeon ® CPU E5-2690 v3 a 2.60 GHz, y con 68 GB de RAM. Sobre este ambiente los tiempos de procesamiento de cada ventana no sobrepasaron los 300 milisegundos considerado en tiempo real con un promedio 258 ms. La **Figura 16** muestra el histograma del tiempo de procesamiento para un usuario en el segundo entorno.



**Figura 15.** Histograma de los resultados de tiempo real sobre el primer ambiente.



**Figura 16.** Histograma de los resultados de tiempo real sobre el segundo ambiente.

### 3.3. Discusión

Al comparar los resultados de los datos de evaluación final del modelo propuesto, observamos que el gesto wave out tiende a confundirse con el gesto fingers spread. Esto puede deberse en parte a que la actividad eléctrica de ambos gestos se toma de la mayoría de los mismos músculos al realizar el gesto de la mano. Ambos gestos son parecidos al momento de iniciar el gesto y la manera de hacer cada gesto puede ser similar para algunos usuarios, en especial cuando se realiza el gesto fingers spread con una leve inclinación.

Comparando los resultados obtenidos del modelo propuesto con los resultados del Myo Armband del trabajo de investigación [39]. La exactitud de reconocimiento promedio es de 83.07% sobre una base de 10 personas y 30 repeticiones por gesto (con una desviación

estándar entre los gestos de la mano de 7,16%). La **Tabla 11** muestra los resultados del sistema de reconocimiento del Myo Armband donde se resalta la exactitud total en color verde y la representación de cada gesto sobre la exactitud total en color amarillo. Se observa que el modelo propuesto supera la exactitud de reconocimiento del modelo Myo Armband. Para el modelo Myo Armband, la sensibilidad más alta es 87% con el gesto fingers spread y el más bajo es 70.33% con el gesto wave in. La precisión más alta es 100% para el gesto wave out y la más baja 82.50% para el gesto fist, se observa una comparación con el modelo propuesto en la **Tabla 12**. A partir de esto podemos decir que el modelo propuesto es más preciso que el sistema del Myo Armband, tomando en cuenta que los gestos realizados en nuestro conjunto de datos son simple observación del usuario sin correcciones de nuestra parte (i.e. el gesto que realiza el usuario es tal como lo comprendió).

**Tabla 11.** Matriz de confusión para el sistema de reconocimiento del Myo Armband [39].

PREDICCIONES	OBSERVACIONES						%PRECISION %ERROR
		WAVE IN	WAVE OUT	FIST	FINGERS SPREAD	DOUBLE TAP	
WAVE IN	221 14,07%	2 0,13%	1 0,07%	0 0,00%	0 0,00%	0 0,00%	98,60% 1,40%
WAVE OUT	0 0,00%	255 17,00%	0 0,00%	0 0,00%	0 0,00%	0 0,00%	100,00% 0,00%
FIST	34 2,27%	1 0,07%	260 17,33%	17 1,13%	3 0,20%	3 0,20%	82,54% 17,46%
FINGERS SPREAD	12 0,80%	6 0,08%	13 0,87%	261 17,40%	1 0,07%	1 0,07%	89,08% 10,92%
DOUBLE TAP	1 0,07%	25 1,67%	4 0,27%	1 0,07%	259 17,27%	1 0,07%	89,31% 10,69%
SIN GESTO	42 2,80%	11 0,73%	22 1,47%	21 1,40%	37 2,47%	37 2,47%	0,00% 100,00%
%SENSIBILIDAD %ERROR	70,33 29,67%	85,00% 15,00%	86,67% 13,33%	87,00% 13,00%	86,33% 13,67%	83,07% 16,93%	

No se puede saber exactamente por qué nuestro modelo funciona mejor que el sistema de reconocimiento del Myo Armband ya que la metodología de reconocimiento de su sistema no se encuentra de manera pública. Sin embargo, en la adquisición de datos se observó que cada persona realiza los gestos de manera diferente y observamos que las señales de EMG tienen diferentes formas para diferentes usuarios. Se puede deducir que un modelo general (i.e., no requiere un entrenamiento previo) como el del Myo Armband tiene una falencia para adaptarse al diferente comportamiento de las señales EMG y de la manera de realizar el gesto de un cada usuario. Por otro lado, un modelo específico se adapta de mejor manera a la forma habitual de realizar el gesto en cada usuario. Los resultados de tiempo del modelo propuesto sobre una computadora de escritorio obligaron a ejecutar

sobre un ambiente computacional de altos recursos para alcanzar un tiempo real ya que se utilizó un clasificador SVM multi-clase uno contra uno, donde se sacrificó una mayor exactitud de reconocimiento para un costo computacional alto.

**Tabla 12.** Comparación de la sensibilidad y precisión.

	WAVE IN	WAVE OUT	FIST	FINGERS SPREAD	DOUBLE TAP
<b>MODELO PROPUESTO</b>					
<b>SENSIBILIDAD</b>	70.33%	85.00%	86.67%	87.00%	86.30%
<b>PRECISIÓN</b>	98.60%	100.00%	82.50%	89.10%	89.30%
<b>MODELO DEL MYO ARMBAND</b>					
<b>SENSIBILIDAD</b>	81.33%	90.80%	90.47%	80.60%	88.47%
<b>PRECISIÓN</b>	91.61%	89.90%	98.55%	91.52%	94.05%

#### 4. CONCLUSIONES

En este trabajo de investigación, se presenta un modelo de reconocimiento de gestos de la mano basado en las señales EMG del antebrazo con un promedio de tiempo de procesamiento de 382 ms en una computadora de escritorio y 258 ms en una computadora de altos recursos computacionales. El modelo propuesto funciona de manera individual y se requiere un entrenamiento de 10 repeticiones por cada uno de los 5 gestos de corta duración de la mano y el gesto de relajación. El modelo propuesto consta de 5 etapas: adquisición de datos, pre-procesamiento, extracción de características, clasificación y post-procesamiento. El dispositivo comercial Myo Armband se utilizó para adquirir las señales EMG. En el pre-procesamiento se rectifica y se filtra la señal EMG. Se usó un análisis wavelet mediante DWT con una descomposición completa de árbol usando una wavelet madre DB25 para la extracción de características de las señales EMG pre-procesada. Para la clasificación, utilizamos una SVM multi-clase con un kernel gaussiano y un enfoque de uno contra uno. Finalmente, se realizó un cambio de estado de un paso sobre el vector de respuesta en el post-procesamiento.

Se compara el rendimiento del modelo propuesto con el sistema de reconocimiento propietario del Myo Armband para reconocer los 5 gestos de la mano: wave in, wave out, fist, fingers spread, y double tap. Como resultado de la comparación, se determina que el modelo propuesto tiene una mayor exactitud de reconocimiento que el sistema Myo Armband, y aunque no se conoce los detalles del modelo propietario del Myo Armband se concluye que un modelo específico por usuario funciona mejor que un modelo general. El modelo propuesto demostró ser bastante completo, ya que funciona en un tiempo de

procesamiento menor de 300 ms; realiza reconocimiento, y no solo clasificación; usa señales EMG en estado transitorio; y es capaz de reconocer 5 gestos de la mano de duración corta con una exactitud de reconocimiento promedio de 87,53%, superando la tasa descrita en el estado de arte (85%). Si bien se realizó una comparación somera entre los resultados obtenidos con los del estado de arte, esta comparación no es completamente justa porque cada modelo mencionado tiene diferencias como: los gestos reconocidos, la cantidad de gestos, metodologías de evaluación. Además, la mayoría de los trabajos no mencionan información relevante como la sensibilidad, precisión, tiempo de procesamiento, desviaciones estándares, muestras de entrenamiento y testeo, etc. Para trabajos futuros, se debe considerar el uso de SVM multi-clase con un enfoque uno contra todos como clasificador, debido a que realiza menos comparaciones reduciendo el tiempo de procesamiento. Además, se puede agregar un número mayor de clasificaciones por ventana de procesamiento para mejorar la exactitud.

## **5. REFERENCIAS BIBLIOGRÁFICAS**

- [1] A. Konar and S. Saha, Gesture Recognition: Principles, Techniques and Applications. Clam: Springer International Publishing, 2018
- [2] S. Reshma and M. Jayaraju, "Spotting and recognition of hand gesture for Indian sign language recognition system with skin segmentation and SVM," 2017 International Conference on Wireless Communications, Signal Processing and Networking (WiSPNET), Chennai, 2017, pp. 386-390.
- [3] C. Savur and F. Sahin, "Real-Time American Sign Language Recognition System Using Surface EMG Signal," 2015 IEEE 14<sup>th</sup> International Conference on Machine Learning and Applications (ICMLA), Miami, FL, 2015, pp. 497-502.
- [4] V. T. Gaikwad and M. M. Sardeshmukh, "Sign Language recognition based on electromyography (EMG) signal using artifical nueral network (ANN)," International Journal of Industrial Electronics and Electrical Engineering, vol. 2, no. 6, pp 73-75, 2014
- [5] N. Wang, K. Lao, and X. Zhang, "Design and Myoelectric Control of an Anthropomorphic Prosthetic Hand," Journal of Bionic Engineering," vol. 14, pp. 47-59, 2017.
- [6] M. Tavakoli, C. Benussi, and J.L. Lourenco, "Single channel surface EMG control of advanced prosthetic hands: A simple, low cost and efficient approach," Expert Systems with Applications, vol. 79, pp. 322- 332, 2017.
- [7] H.S. Grif, and C.C. Farcas, "Mouse Cursor Control System Based on Hand Gesture," Procedia Technology, vol. 22, pp. 657-661, 2016.
- [8] S.S. Rautaray, and A. Agrawal, "Manipulating Objects through Hand Gesture Recognition in Virtual Environment," in Advances in Parallel Distributed Computing, D. Nagamalai, E. Renault, and M. Dhanuskodi, Eds. Springer Berlin Heidelberg, 2011, pp. 270-281.
- [9] Y. Xu and Y. Dai, "Review of hand gesture recognition study and application," Contemporary Engineering Sciences, Vol. 10, no. 8, pp 375 - 384, 2017.

- [10] K. Englehart and B. Hudgins, "A Robust, Real-Time Control Scheme for Multifunction Myoelectric Control," *IEEE Trans. Biomed. Eng.*, vol. 50, no. 7, pp. 848–854, 2003.
- [11] P. Polygerinos, K. C. Galloway, S. Sanan, M. Herman and C. J. Walsh, "EMG controlled soft robotic glove for assistance during activities of daily living," *2015 IEEE International Conference on Rehabilitation Robotics (ICORR)*, Singapore, 2015, pp. 55-60.
- [12] G. Marin, F. Dominio and P. Zanuttigh, "Hand gesture recognition with leap motion and kinect devices," *2014 IEEE International Conference on Image Processing (ICIP)*, Paris, 2014, pp. 1565-1569.
- [13] C. J. De Luca. "Electromyographic. Encyclopedia of Medical Devices and Instrumentation". Ed. John G. Webster. 2006. Massachusetts. Ed. John Wiley Publisher, pp 98-106
- [14] L Weiss, J. Weiss, and J. Silver, "Easy EMG", Elsevier, 2016.
- [15] E. H. Shroffe , P. Manimegalai, "Hand gesture recognition based on EMG signals using ANN," *international journal of computer application*. 2013, vol 2, no. 3, pp 31–39.
- [16] S. Benatti et al., "A sub-10mW real-time implementation for EMG hand gesture recognition based on a multi-core biomedical SoC," *2017 7<sup>th</sup> IEEE International Workshop on Advances in Sensors and Interfaces (IWASI)*, Vieste, 2017, pp. 139-144.
- [17] M, Mobarak, M. Salgado, R. Guerrero, and V. Dorr, "Transient state analysis of the multichannel emg signal using hjorth's parameters for identification of hand movements." 2014 In *International Multi- Conference on Computing in the Global Information Technology, ICCGI 2014*.
- [18] Z. Xu, C. Xiang, V. Lantz , W. Kong-qiao , W. Wen-hui y Y. Ji-hai, «Hand gesture recognition and virtual game control based on 3D accelerometer and EMG sensors,» *Proceedingsc of the 13<sup>th</sup> international conference on Intelligent user interfaces - IUI '09*, pp. 401-405, 2008

- [19] J. Bronzino, The Biomedical Engineering Handbook: Second Edition., Connecticut, USA: CRC Press LLC, 1999.
- [20] J. Rodriguez-Falces, J. Navallas y A. Mal, « EMG Modeling, » Computational Intelligence in Electromyography Analysis - A Perspective on Current Applications and Future Challenges, pp. 3 - 36, 2012
- [21] J. Basmajian y C. De Luca, Muscle Alive: Their Function Revealed by Electromyography., Baltimore: Willians & Wilkins, 1985
- [22] L. Tagliapietra, M. Vivian, M. Sartori, D. Farina and M. Reggiani, "Estimating EMG signals to drive neuromusculoskeletal models in cyclic rehabilitation movements," 2015 37<sup>th</sup> Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC), Milan, 2015, pp. 3611-3614.
- [23] M. Mobarak, M. Salgado, R. Guerrero, and V. Dorr, "Transient state analysis of the multichannel emg signal using hjorth's parameters for identification of hand movements." 2014 In International Multi- Conference on Computing in the Global Information Technology, ICCGI 2014.
- [24] K. Englehart, B. Hudgin and P. A. Parker, "A wavelet-based continuous classification scheme for multifunction myoelectric control," in IEEE Transactions on Biomedical Engineering, vol. 48, no. 3, pp. 302-311, March 2001.
- [25] R. H. Chowdhury, M. B. I. Reaz, M. A. B. Mohd Ali, A. A. Bakar, K. Chellappan and T. G. Chang, "Surface Electromyography Signal Processing and Classification Techniques," Sensors, Vol. 13, pp. 12431-12466, 2013.
- [26] Continuous and Discrete Wavelet Transforms- MATLAB & Simulink", Mathworks.com, 2018. [Online]. Available: <https://www.mathworks.com/help/wavelet/gs/continuous-and-discrete-wavelet-transforms.html>. [Accessed: 09- Dec- 2018].
- [27] H. Dong, "Detection of Electrocardiography Based on Wavelet Transform and Extended Kalman Filter," 2012 4th International Conference on Intelligent Human-Machine Systems and Cybernetics, Nanchang, Jiangxi, 2012, pp. 138-140.

- [28] W. Du and Z. Zhang, "Application of Wavelet Analysis in Seismic Data Processing of Volcanic Rock Region," 2010 International Conference on Intelligent System Design and Engineering Application, Changsha, 2010, pp. 371-374.
- [29] Rong Sun, Y. W. Marye and Hua-An Zhao, "Wavelet transform digital sound processing to identify wild bird species," 2013 International Conference on Wavelet Analysis and Pattern Recognition, Tianjin, 2013, pp. 306-309.
- [30] Naiwei Wang, Yingguang Zhang and Shunjun Wu, "Radar waveform design and target detection using wavelets," 2001 CIE International Conference on Radar Proceedings (Cat No.01TH8559), Beijing, China, 2001, pp. 506-509.
- [31] Burrus C, Gopinath R, Guo H. Introduction to Wavelets and Wavelet Transforms. Prentice Hall. 1998. Pags: 1-40
- [32] J. Too , A. R. Abdullah, N. Mohd Saad , N. Mohd Ali , H Musa, "A Detail Study of Wavelet Families for EMG Pattern Recognition," International Journal of Electrical and Computer Engineering (IJECE), vol. 8, no. 6, pp. 4221-4229, 2018.
- [33] R. J. Oweis, R. Rihani, and A. Alkhawaja, "Ann-based emg classification for myoelectric control," International Journal of Medical Engineering and Informatics, vol. 6, no. 4, pp. 365–380, 2014.
- [34] H. Ling, Y. Bo, and Z. Lina, "Clustering analysis and recognition of the emgs," in Intelligent Control and Information Processing (ICICIP), 2011 2nd International Conference on, vol. 1. IEEE, 2011, pp. 243– 246.
- [35] Z. Wu and X. Li, "A wireless surface EMG acquisition and gesture recognition system," 2016 9<sup>th</sup> International Congress on Image and Signal Processing, BioMedical Engineering and Informatics (CISP-BMEI), Datong, 2016, pp. 1675-1679.
- [36] E. H. Shroffe , P. Manimegalai, "Hand gesture recognition based on EMG signals using ANN," international journal of computer application. 2013, vol 2, no. 3, pp 31–39.
- [37] J. Wang, H. Ren, W. Chen and P. Zhang, "A portable artificial robotic hand controlled by EMG signal using ANN classifier," 2015 IEEE International Conference on Information and Automation, Lijiang, 2015, pp. 2709-2714.

- [38] R. Alba-Flores, S. Hickman and A. S. Mirzakani, "Performance analysis of two ANN based classifiers for EMG signals to identify hand motions," SoutheastCon 2016, Norfolk, VA, 2016, pp. 1-5.
- [39] M. E. Benalcázar, A. G. Jaramillo, Jonathan, A. Zea, A. Páez and V. H. Andaluz, "Hand gesture recognition using machine learning and the Myo armband," 2017 25th European Signal Processing Conference (EUSIPCO), Kos, 2017, pp. 1040-1044.
- [40] R. Agarwal, B. Raman and A. Mittal, "Hand gesture recognition using discrete wavelet transform and support vector machine," 2015 2nd International Conference on Signal Processing and Integrated Networks (SPIN), Noida, 2015, pp. 489-493.
- [41] Giddu Anthony, Hulley Gregg and Marwala," Image Classification using SVM: one-against-one vs one –against-all", Xiv:0711.2914, arxiv.org, 2007

## **6. ANEXOS**

ANEXO I. Exactitud promedio de cada usuario del conjunto de validación y evaluación final.

## **ANEXO I**

**Exactitud promedio de cada usuario del conjunto de validación y evaluación final**

Conjunto de Datos de Validación		Conjunto de Datos de Evaluación Final	
Usuario	Exactitud	Usuario	Exactitud
1	96,00%	1	96,80%
2	82,40%	2	92,00%
3	84,00%	3	64,00%
4	86,40%	4	83,20%
5	99,20%	5	82,40%
6	88,80%	6	78,40%
7	96,80%	7	56,80%
8	98,40%	8	97,60%
9	95,20%	9	92,80%
10	100,00%	10	87,20%
11	89,60%	11	86,40%
12	95,20%	12	92,00%
13	91,20%	13	96,80%
14	79,20%	14	86,40%
15	81,60%	15	79,20%
16	68,80%	16	92,80%
17	90,40%	17	97,60%
18	86,40%	18	98,40%
19	78,40%	19	96,80%
20	83,20%	20	89,60%
21	92,00%	21	99,20%

22	87,20%	22	61,60%
23	94,40%	23	83,20%
24	72,80%	24	97,60%
25	83,20%	25	76,80%
26	89,60%	26	97,60%
27	98,40%	27	84,80%
28	92,00%	28	95,20%
29	87,20%	29	85,60%
30	88,00%	30	55,20%
31	92,80%	31	95,20%
32	95,20%	32	85,60%
33	90,40%	33	94,40%
34	97,60%	34	98,40%
35	92,00%	35	80,80%
36	96,00%	36	95,20%
37	80,80%	37	80,00%
38	92,80%	38	90,40%
39	65,60%	39	92,80%
40	89,60%	40	92,80%
41	73,60%	41	98,40%
42	88,80%	42	99,20%
43	88,80%	43	92,80%
44	81,60%	44	68,80%
45	100,00%	45	92,00%

46	92,00%	46	92,00%
47	73,60%	47	36,80%
48	89,60%	48	83,20%
49	98,40%	49	99,20%
50	98,40%	50	98,40%
51	90,40%	51	89,60%
52	87,20%	52	95,20%
53	85,60%	53	75,20%
54	84,00%	54	97,60%
55	87,20%	55	94,40%
56	88,00%	56	96,00%
57	59,20%	57	98,40%
58	94,40%	58	93,60%
59	98,40%	59	75,20%
60	74,40%	60	86,40%